Проект: Векторная модель M&A сделок

1. Описание проекта

Исторически рынок слияний и поглощений (M&A) опирается на экспертную интуицию и ручной анализ. Каждая сделка уникальна: разные чеки, специфические условия, разные индустрии и корпоративные культуры. Именно этот фактор субъективизма мешает инвестиционным фондам и банкам выстраивать прозрачный процесс сравнения сделок. Аналитики тратят сотни часов на поиск релевантных аналогов, а руководство зачастую не может объективно оценить, почему одна сделка закрылась за три месяца, а другая застряла на этапе Due Diligence уже полгода. Возникает потребность в инструменте, который переведет «уникальность» в формат вычисляемых математических величин.

2. Математика вектора

$T = F_{base} * (\alpha * N_{vec} + \beta * S_{graph}) * e^{-\gamma * H_{friction}}$

Элементы главной формулы:

- Итоговый скоринговый балл (T) < 0 (отказ), ≈ 0 (рискованная сделка), > 0 (приоритетная покупка)
- Сложение потенциалов: Новизна (N_{vec}) и Синергия (S_{graph}) складываются. При нулевой синергии сделка может быть интересна высокой новизной.
- α (Альфа) и β (Бета): α повышается для венчурных/технологических сделок (фокус на новизну). β повышается для Bolt-on сделок (фокус на захват рынка).
- Экспоненциальный штраф: Интеграционный риск ($H_{friction}$) стоит в отрицательной степени экспоненты (e). Чем выше хаос, тем сильнее множитель стремится к 0, снижая стратегическую ценность.

$N_{vec} = \|V_A - V_B\|_2 * exp(\frac{\|V_A - V_B\|_2^2}{2\sigma^2})$

Компоненты и источники данных:

- V_A, V_B: Векторные центроиды бизнесов Покупателя (A) и Цели (T). Берутся из векторизации текстовых описаний, патентов, документов
- $\|V_A - V_B\|_2$: Евклидово расстояние (фактическая разница между компаниями).
- $2\sigma^2$ (сигма в квадрате): Математически отражает запас прочности команды при слияние с новыми компаниями. Если дистанция превышает этот запас, экспонента уводит балл новизны в 0

$$S_{graph} = \frac{1}{Z} \sum_{i \epsilon G_A} \sum_{j \epsilon G_T} w_{ij} * \ log(1 + max(0, \Delta C_B(i,j)))$$

Компоненты и источники данных:

- Узлы графа: i – текущие клиенты-покупателя, j – продукты/услуги
- Z (базовая выручка покупателя) – это нормализатор, преобразующий абсолютные значения синергетического эффекта в относительные величины для обеспечения математической сопоставимости параметров модели
- G_A и G_T – это математическое представление двух объединяемых компаний в виде графов (сетей)
- $\Delta C_B(i,j)$: Прирост показателя центральности по посредничеству – метрики, измеряющей, насколько часто компания оказывается на кратчайших путях между другими участниками рынка
- w_{ij}: Вес транзакции (ожидаемый LTV, ARPU или конверсия) от кросс-продажи продукта j клиенту i (из финмодели)

$$H_{friction} = \ -\sum_{k=1}^{k} P(x_k) * \log_2 P(x_k)$$

$$P(x_k) \ = \frac{P((D_k|C_k) * P(C_k)}{P(D_k)}$$

- P(x_k) – вероятность конфликта в бизнес-процессе при попытке объединения
- $P(C_k)$ – базовая историческая вероятность конфликта в этом бизнес-процессе по рынку (до начала проверки)
- $P((D_k|C_k)$ – точность аудиторов (вероятность того, что они найдут «стоп факторы» D_k, если процесс действительно несовместим)
- $P(D_k)$ – общая частота, с которой подобные «стоп факторы» (например, отсутствие лицензий) встречаются на этом рынке

$$F_{base} = \ tanh\ (\lambda * \frac{FCF}{WACC * Enterprise\ Value})$$

Компоненты и источники данных:

- tanh (гиперболический тангенс): Нелинейный нормализатор. Сжимает балл от -1 (нестабильность) до 1 (нейтрально). Не позволяет огромной прибыли перевесить новизну, но обнуляет итоговый показатель при колоссальных убытках
- FCF: Свободный денежный поток
- WACC: Стоимость долга/капитала
- Enterprise Value: Запрашиваемая стоимость сделки
- λ (лямбда): Калибровочный коэффициент/стратегия фонда. Высокая λ (консервативный фонд, важна окупаемость сразу), низкая λ (венчурный фонд, готов покупать убыточные прорывные стартапы для последующего совместного развития).

3. Практическая ценность модели

Внедрение векторной модели делает процесс отбора таргетов прозрачным и предсказуемым, снижая влияние субъективных оценок. Опираясь на измеримые семантические, топологические и финансовые метрики, модель позволяет избежать эмоциональных решений. Интеграция теоремы Байеса дает возможность обновлять скоринг прямо в ходе Due Diligence: новые риски, обнаруженные в Data Room, автоматически корректируют вероятность успешной интеграции и итоговый балл без пересмотра всей структуры расчета. Коэффициенты обеспечивают гибкое управление воронкой сделок, позволяя инвестиционному комитету быстро адаптировать рейтинг проектов под смену стратегии – например, перенести фокус с поиска инноваций на расширение доли рынка. Кроме того, применение графовой топологии выявляет скрытую синергию, которую часто упускают классические финансовые подходы. Алгоритм подсвечивает неочевидные точки роста и выделяет активы, присоединение которых позволит объединить клиентские потоки, а не ограничиваться стандартным сокращением издержек.

4. Вывод

Главный итог применения математической модели – переход от интуитивного выбора активов к доказательному анализу. Модель задает единую систему координат для инвестиционного комитета, сводя разрозненные финансовые, юридические и технические данные к общему знаменателю. На практике это позволяет фонду эффективнее работать с воронкой сделок: быстро отсекать проблемные компании на ранних этапах проверки и направлять ресурсы только на те активы, которые действительно способны масштабировать текущий бизнес. В результате сложный и часто субъективный процесс M&A становится

прозрачным и прогнозируемым, что помогает защитить капитал от скрытых операционных рисков при слиянии.